

PROJETO INTERDISCIPLINAR · ASA

Relatório Técnico e Model Card

Entrega 1 — Parcial · Agente de Monitoramento de Estudantes ou Agente de Pendências

Este relatório documenta a construção de uma baseline (primeira versão simples do modelo) coerente com o agente escolhido, seguindo os requisitos da Entrega 1 do Projeto Interdisciplinar.

1. Análise dos Dados

Abaixo estão descritas as bases de dados utilizadas no projeto, detalhando as fontes, a quantidade de registros, o conteúdo abrangido e a respectiva granularidade de cada arquivo.

Fonte	Registros	Conteúdo	Observações
Base Histórica de Alunos (ASA)	12.846 (12.839 após limpeza)	Dados acadêmicos, financeiros, relacionais e geográficos dos alunos.	1 linha por aluno. Base original fornecida pelo ASA para a modelagem preditiva.
Base Normativa / Documentos Oficiais	Múltiplos docs PDF	Normativas, regulamentos, manuais e procedimentos operacionais do ASA.	Documentos institucionais vigentes indexados para busca semântica (RAG).
Logs de Interação e Atendimento	Variável	Histórico de atendimentos presenciais, chamados e interações no chat.	Utilizado para acompanhamento da jornada e métrica de relacionamento.

2. Preparação dos Dados

Nesta seção, documentam-se os principais desafios de qualidade identificados nos dados brutos, as ações de higienização aplicadas e a estratégia utilizada para a unificação das tabelas.

- Saneamento e Tratamento de Duplicidades:** A base de dados original fornecida pelo ASA continha 12.846 registros. Durante a análise inicial, identificaram-se IDs de alunos duplicados e problemas de inconsistência em atributos. Após a remoção e tratamento das duplicidades, mantiveram-se 12.839 registros válidos para modelagem.
- Tratamento de Valores Nulos e Inconsistências:** Foram identificados valores ausentes em atributos acadêmicos, financeiros e geográficos, além de formatos inconsistentes. Realizou-se a imputação e padronização das variáveis, garantindo a integridade dos dados.
- Unificação de Tabelas e Agregação:** As informações provenientes de diferentes fontes (acadêmica, financeira, relacionamento e geográfica) foram unificadas utilizando o identificador único do aluno (ID/hash do aluno) como chave de junção. A agregação dos dados foi realizada na granularidade de 1 linha por aluno, consolidando históricos de notas, assiduidade, atrasos de pagamento e contatos em métricas sintéticas por estudante.
- Prevenção de Vazamento Temporal:** Para evitar vazamento temporal de informação, todas as variáveis explicativas foram calculadas estritamente com data de corte anterior ao desfecho do evento de evasão.

3. Seleção de Atributos

Abaixo estão listados os atributos (features) selecionados para a construção do modelo preditivo, organizados por dimensão com suas respectivas justificativas de relevância para o problema de evasão.

Dimensão	Atributo	Justificativa
Financeira	atraso_medio_dias, pct_parcelas_em_aberto, pct_parcelas_acordo, existencia_bolsa	Mede o nível de inadimplência e a saúde financeira do estudante, fatores fortemente correlacionados ao risco de trancamento.
Acadêmica	media_notas, media_assiduidade, pct_reprovacao, tendencia_notas, tendencia_assiduidade	Avalia o desempenho escolar, o engajamento em sala de aula e oscilações recentes na vida acadêmica do aluno.
Relacionamento	total_contatos, dias_desde_ultimo_contato	Mede a frequência e recência das interações do aluno com o ASA, sinalizando demanda de suporte ou isolamento.
Geográfica	distancia_km	Mede a distância física entre a residência do aluno e o campus, influenciando custos de deslocamento e assiduidade.
Perfil do Curso	periodo, turno, forma_ingresso	Permite contextualizar a trajetória acadêmica e identificar padrões de risco por turno ou momento do curso.

4. Definição das Métricas

Para avaliar a baseline foram utilizadas as métricas acurácia, precisão, recall e F1-score. A acurácia representa a proporção total de classificações realizadas corretamente pelo modelo. A precisão permite avaliar, entre os estudantes classificados pelo modelo como evasão, quantos efetivamente pertenciam à classe de evasão. O recall avalia a capacidade do modelo de identificar os casos de evasão existentes na base. Essa métrica é especialmente relevante para o contexto de monitoramento, pois permite observar quantos dos casos reais de evasão foram identificados pela baseline. O F1-score representa o equilíbrio entre precisão e recall.

5. Baseline do Agente

O agente desenvolvido nesta etapa tem como objetivo auxiliar no monitoramento dos estudantes. Para isso, utilizamos os atributos selecionados anteriormente para estimar o risco de evasão. Como modelo inicial, foi utilizado o Random Forest Classifier. A probabilidade estimada pelo Random Forest para a classe evadiu = 1 foi convertida em um score de 0 a 100:

Score de risco = Probabilidade estimada de evasão × 100

Foram estabelecidos os seguintes limiares iniciais:

Score Classificação	Legenda	Interpretação
Menor que 30	Verde	Risco inicial baixo
De 30 a menor que 60	Amarelo	Caso que demanda atenção
Igual ou superior a 60	Vermelho	Risco inicial mais elevado

Resultado:

Classificação	Quantidade
Verde	1937
Amarelo	346
Vermelho	285

Explicação dos fatores:

A importância das variáveis foi analisada utilizando o atributo `feature_importances_` do Random Forest. As variáveis que apresentaram maior importância para o modelo foram:

Atributo	Importância
distancia_km	21,82%
media_notas	14,36%
dias_desde_ultimo_contato	12,41%
atraso_medio_dias	9,59%
media_assiduidade	8,43%
pct_parcelas_em_aberto	7,66%
total_contatos	5,40%
tendencia_assiduidade	4,38%
tendencia_notas	4,24%
pct_parcelas_acordo	3,18%

A variável de maior importância na baseline foi `distancia_km`, seguida por `media_notas` e `dias_desde_ultimo_contato`.

Essas importâncias indicam quais atributos foram mais utilizados pelo Random Forest para realizar suas classificações. Entretanto, não significam que esses fatores sejam causas da evasão. Os resultados representam associações identificadas pelo modelo nos dados utilizados e precisam ser interpretados considerando as limitações da base.

6. Limitações Conhecidas

Como esta é a primeira versão da baseline, ainda existem algumas limitações. Durante a análise foram encontrados valores ausentes, IDs duplicados e alguns atributos com formatos inconsistentes. Além disso, os limites utilizados para classificar os estudantes como Verde, Amarelo ou Vermelho são iniciais e ainda precisam ser avaliados.

Outro ponto importante é que a importância apresentada pelo Random Forest mostra quais variáveis tiveram maior participação nas classificações do modelo, mas não significa que elas sejam diretamente responsáveis pela evasão.

7. Próximos Passos

Os próximos passos no desenvolvimento do SISA serão:

- Validar a limpeza dos dados com a origem da base;
- Revisar o tratamento dos IDs duplicados;
- Comparar a Random Forest com outros modelos;
- Avaliar métricas adicionais;
- Revisar os limiares do score;
- Ampliar a explicabilidade;

Model Card (Primeira Versão)

Detalhes do Modelo

SISA – Sistema Inteligente do Sucesso Alvarista

Versão: 1.0 – Baseline

Data: 11/09/2026

Algoritmo: Random Forest Classifier

Grupo: ArregASA - projeto 1

Uso Pretendido

O modelo foi desenvolvido para apoiar os funcionários do ASA na identificação de padrões associados ao risco de evasão. O modelo deve ser utilizado exclusivamente como ferramenta de apoio à análise humana. A classificação gerada não deve ser interpretada como decisão definitiva sobre um estudante e não deve ser utilizada para aplicar sanções, restringir direitos, cancelar benefícios ou executar automaticamente qualquer decisão acadêmica ou administrativa.

Dados de Treinamento

A baseline foi desenvolvida utilizando a base de dados fornecida pelo ASA, a base original possui 12.846 registros e após o tratamento inicial das duplicidades, foram utilizados 12.839 registros.

Foram selecionados 14 atributos, provenientes das dimensões acadêmica, financeira, de relacionamento e geográfica.

Entre os principais atributos utilizados estão média de notas, média de assiduidade, percentual de reprovação, mudanças recentes em notas e assiduidade, tendências acadêmicas, parcelas em aberto, parcelas em acordo, atraso médio, existência de bolsa, quantidade de contatos, dias desde o último contato e distância.

Avaliação

A avaliação preliminar da baseline foi realizada sobre um conjunto de teste com 2.568 registros.

Os resultados obtidos foram:

Métrica	Resultado
Acurácia	80,61%
Precisão	50,66%
Recall	38,37%
F1-score	43,67%

Considerações Éticas

O score deve funcionar como apoio ao monitoramento. A classificação não representa uma decisão definitiva sobre o estudante e deve ser analisada por uma pessoa responsável. Dados pessoais devem ser tratados apenas para a finalidade prevista no projeto.

Limitações

A baseline foi construída a partir de uma base que apresenta valores ausentes, duplicidades e inconsistências de formato em alguns atributos. Além disso, os limiares utilizados para a classificação de risco ainda precisam ser validados.

Histórico de Versões

Versão	Data	Alterações
1.0	11/09/2026	Criação da primeira baseline do Agente, utilizando Random Forest, definição inicial do score de risco e avaliação preliminar.