PROJETO INTERDISCIPLINAR · SISA

Relatório Técnico e Model Card

Entrega 2

Objetivo: Documentar a avaliação do Agente 2, que auxilia funcionários do ASA no atendimento ao Aluno, ajudando a interpretar solicitações, identificar requerimentos do catálogo, indicar setor e prioridade, resumir o pedido, sugerir próximos passos e se abster quando faltam informações.

1. Escopo e Metodologia

A avaliação foi realizada pelo notebook, que inicia a API FastAPI do backend e testa o endpoint POST /api/staff/requirement-assistant, o mesmo utilizado pelo aplicativo. Foram comparadas três configurações: baseline baseada em regras, LLM sem contexto e LLM com recuperação de informações (RAG).

O conjunto contém 20 casos: 14 respondíveis e 6 em que a resposta esperada é a abstenção. Os casos cobrem diferentes intenções, prioridades e estilos de escrita, incluindo linguagem formal, informal, abreviada, ambígua, contraditória, fora de escopo e adversarial. Os rótulos de referência foram definidos pela equipe a partir do catálogo oficial e devem ser revisados por funcionários do ASA antes de serem tratados como gabarito definitivo.

A execução registrada usou o modelo qwen/qwen3.8-27b via Groq, catálogo com 82 requerimentos e índice RAG com 257 trechos de 14 documentos disponibilizados pelo ASA.

As métricas de qualidade apresentadas foram calculadas sobre respostas previamente armazenadas em cache. Os testes de integração da API foram executados e reportados separadamente. Portanto, os resultados são evidência da avaliação registrada no notebook, mas a comparação de qualidade deve ser repetida diretamente no app antes de uma conclusão definitiva.

2. Testes de integração e serviço de inferência

O notebook registrou 18 de 18 testes de integração como PASSOU. Os testes cobriram:

- Saúde da API e endpoint de versão, incluindo informações de prompt, modelo e base de conhecimento.
- Requisição válida e presença dos campos esperados no contrato de resposta.
- Validação de entradas inválidas: texto vazio, campo ausente, configuração inválida e texto acima de 5.000 caracteres (retorno 422).
- Comportamento degradado quando o serviço de IA falha, com retorno pelo baseline.
- Execução de llm_rag e registro do modelo efetivo; regressão do endpoint de chat.

- Desempenho do baseline abaixo de 2 segundos (104 ms no teste registrado).
- Suíte pytest: 14 testes aprovados em 9,44 segundos.
- Integração com o aplicativo: chamada ao endpoint, URL configurável por EXPO_PUBLIC_BACKEND_URL, cartão exibido apenas para perfil Funcionário e compatibilidade dos campos.
- Verificação de que o cliente Groq não contém uma chave fixa no código.

3. Comparação quantitativa

A tabela resume as métricas principais apresentadas no notebook. As métricas de classificação usam os 14 casos respondíveis e 6 de abstenção. As métricas de abstenção consideram os casos de resposta e de abstenção.

Configuração	Identificação	setor	Recall	Acurácia Prioridade	F1 Macro Prioridade	Fatos-chave	Fundamentadas	Próximos passos
Baseline de Regras	64%	64%	93%	57%	48%	100%	100%	98%
LLM sem contexto	100%	86%	93%	100%	100%	100%	100%	95%
LLM RAG	93%	93%	93%	93%	93%	100%	95%	98%

Configuração	Precisão Abstenção	Recall Abstenção	F1 Abstenção	Abstenção indevida
Baseline de Regras	67%	67%	67%	14%
LLM sem contexto	67%	80%	80%	0%
LLM RAG	100%	67%	80%	0%

3.1 Interpretação dos Resultados

Identificação do requerimento: A baseline acertou 64% dos requerimentos, enquanto o LLM sem contexto atingiu 100% e o LLM com RAG 93%. O resultado sugere que o LLM sem contexto acertou todos os casos respondíveis registrados. O RAG teve desempenho próximo, enquanto a baseline errou mais de um terço dos casos. Essa métrica avalia a escolha final do requerimento.

Setor responsável: A taxa registrada foi 64% na baseline, 86% no LLM sem contexto e 93% no LLM + RAG. O RAG teve melhor resultado nesta dimensão, coerente com o uso de informações recuperadas.

Prioridade: O F1 macro foi 48% na baseline e 100% para LLM sem contexto, e 93% para LLM + RAG. A baseline apresentou desempenho fraco na classificação de prioridades, incluindo casos

de prioridade subestimada e superestimada. O LLM sem contexto acertou todas as classes nos casos registrados; o RAG também teve resultado alto, mas com um erro de prioridade subestimada.

Abstenção: A abstenção é a decisão de não oferecer uma orientação conclusiva quando a solicitação é ambígua, contraditória, insuficiente ou fora do escopo. O resumo final do notebook informa F1 de abstenção de 80% para as configurações LLM e recall de abstenção de aproximadamente 67%. Isso significa que o sistema ainda deixou de se abster em parte dos casos que deveriam ser encaminhados para esclarecimento ou revisão. A abstenção precisa ser tratada como controle de segurança, não apenas como uma métrica secundária.

Resumo e fundamentação: A cobertura automática de fatos-chave foi de 100% nas três configurações, e a verificação automática classificou 100% das respostas da baseline e do LLM sem contexto, e 95% das respostas RAG como fundamentadas. Ainda assim, a análise de erros sinalizou informação não suportada em 1 caso do LLM sem contexto e 2 casos do RAG. Essa diferença indica que o resultado agregado deve ser conferido com os casos individuais. A métrica automática não substitui a revisão humana nem garante ausência de alucinações.

Próximos passos: A pontuação automática foi alta (95% no LLM sem contexto; 98% no RAG e na baseline). Essa nota verifica critérios estruturais observáveis e não garante, por si só, que cada orientação esteja atualizada, seja executável ou corresponda às políticas acadêmicas vigentes.

4. Viés e equidade por estilo de escrita

A análise identificou uma diferença de 44 pontos percentuais na identificação entre textos formais e informais/abreviados para a baseline, e de 17 pontos percentuais para o RAG. O LLM sem contexto apresentou gap observado de 0 ponto percentual nesse conjunto. A configuração sem contexto acertou todas as formas testadas para as sete intenções consideradas; o RAG acertou todas as formas em 86% das intenções e ao menos uma forma em 100%.

Esses números indicam possível viés de linguagem da baseline e uma diferença residual no RAG.

5. Limiares, explicabilidade e versionamento

O notebook registrou um limiar de confiança de 90. A análise indicou que o melhor acerto efetivo foi de 65%, observado em uma faixa de limiares entre 40 e 100. Como o limiar atual está dentro dessa faixa de desempenho semelhante, não há evidência, neste teste, de que alterá-lo traria uma melhora significativa. No entanto, como a calibração foi realizada no próprio conjunto de teste, esses resultados são exploratórios e precisam ser confirmados com casos independentes.

Para favorecer a explicabilidade e a auditoria, o notebook registra exemplos detalhados e logs com informações como configuração do agente, modelo utilizado, versão do prompt, requerimento

selecionado, candidatos do catálogo, trechos recuperados, alertas e latência. Esses registros permitem acompanhar como o agente chegou a uma resposta e investigar possíveis falhas.

O manifesto de execução identifica o agente como versão 1.0.0, o prompt como p1-e38774915a, o modelo como qwen/qwen3.8-27b e o conjunto de testes como versão 1.1, composto por 20 casos. Também registra o hash dos arquivos e metadados da base de conhecimento, contribuindo para a rastreabilidade dos resultados. O manifesto da execução registra o agente como versão 1.0.0. Essa identificação, porém, corresponde à versão declarada no teste: o código já está em sua terceira versão de desenvolvimento. Portanto, o número 1.0.0 não representa a primeira versão do código, mas a versão registrada pelo manifesto durante essa execução.

6. Escolha da configuração

O notebook comparou diferentes configurações e selecionou a llm_sem_contexto | qwen3.8-27b, que utiliza um modelo de linguagem para interpretar as solicitações dos alunos, sem consultar documentos externos por meio de RAG.

Ela foi escolhida porque alcançou 85% de utilidade média, considerando o conjunto de critérios utilizados pelo notebook:

- Identificação correta — 100%: o modelo conseguiu identificar corretamente o requerimento correspondente à solicitação em todos os casos avaliados que permitiam uma resposta.
- F1 macro de prioridade — 100%: apresentou um resultado perfeito na avaliação da classificação de prioridades, considerando as diferentes categorias.
- F1 de abstenção — 80%: teve um bom resultado ao identificar situações em que deveria evitar responder e solicitar uma análise ou esclarecimento. Porém, ainda houve falhas.
- Qualidade dos próximos passos — 95%: as orientações sobre o que fazer em seguida atenderam à maioria dos critérios avaliados.
- Fundamentação — 100%: o verificador automático classificou todas as respostas como fundamentadas. Mesmo assim, isso não garante que todas as informações estejam corretas, pois foram identificados casos de informações não suportadas.

7. Limitações

- A amostra é pequena (20 casos, dos quais 14 respondíveis) e não sustenta generalização ampla.

- As métricas de qualidade foram calculadas sobre respostas em cache nesta execução registrada; devem ser reproduzidas sem cache.
- O gabarito foi definido pela equipe e ainda precisa de validação humana.
- A avaliação de estilos não equivale a uma análise de equidade demográfica.
- A pontuação de próximos passos e a verificação de fundamentação são automáticas e podem não capturar todos os erros semânticos.
- O juiz LLM é auxiliar e não deve ser tratado como referência absoluta; a revisão humana é necessária.
- A latência de LLM/RAG é substancialmente maior que a baseline.

8. Conclusão

O Agente foi integrado ao aplicativo e apresentou resultados positivos nos testes realizados. Após essa avaliação, a equipe está trabalhando na correção dos pontos que mais precisam de melhorias, como a segurança das respostas, a capacidade de abstenção e o tempo de resposta. Além disso, o agente está sendo aprimorado com novos documentos para ampliar sua base de conhecimento e melhorar a qualidade das informações fornecidas. O objetivo é continuar sua evolução até que alcance um nível de confiabilidade e segurança que permita sua utilização sem supervisão humana.